

2026 성균관대학교 멀티모달 AI Bias 챌린지 · 최종 제출 발표

SIMPLER IS BETTER

GRPO-only로 멀티모달 AI 편향을 완화하다

복잡도가 이득을 못 내는 8B RLVR의 한계에 대한 음성결과 기반 연구

base: Qwen3-VL-8B-Instruct[7] (Apache-2.0) · 최종 제출 모델 **HardNeg-GRPO**

TEAM **pk42ac**

박성호 · 2026.06

코드·실험 github.com/Sungho-pk42ac/dacon-2026-skku-multimodal-ai-bias-challenge · 모델 huggingface.co/psh3333/dacon-skku-bias-vlm-v6

CONTENTS

01 OVERVIEW

P.03–10

30초 요약 · 용어

배경 · 동기

Abstract

과제 · 기여

Related Work

계보 · 사양

02 METHOD

P.11–19

왜 GRPO인가

알고리즘 · 보상

학습데이터 설계

강건성·일반화

재현 절차

03 RESULTS

P.20–24

복잡도 기각

인분포 결과

독립 일반화

DACON 채점

04 DISCUSSION

P.25–28

논의 3가지

최종 모델 선택

음성결과

한계

05 CLOSING

P.29–34

Future Work · 결론

학습로그 · 비교표

References

30-SECOND SUMMARY & KEY TERMS

30초 요약과 핵심 용어 — 이 5개만 알면 끝까지 편합니다

30초 요약

AI가 이미지 속 사람을 **성별·인종 같은 고정관념**으로 판단하지 않게 만드는 게 목표입니다.

우리는 **가장 단순한 방법(GRPO 하나)**만으로 편향을 없앴고, 더 복잡한 방법을 4가지나 시도했지만 **이보다 더 나아지지 않았습니다**.

그래서 결론은 — “**정교함이 아니라 단순함이 이겼다.**”

GRPO — 한 문제에 답을 여러 개 내보고, 그중 잘한 답 쪽으로 스스로 학습하는 강화학습. 따로 채점용 모델이 필요 없어 가볍다.

하드네거티브 — 모델이 자주 틀리는 어려운 문제만 골라 가르치는 것. 다 맞는 쉬운 문제만 주면 배울 게 없다.

OOD · 독립셋 — 학습에 한 번도 안 쓴 새로운 문제. 외운 게 아니라 진짜 실력(일반화)이 있는지 본다.

ablation (제거 실험) — 요소를 하나씩 빼 보며 “무엇이 진짜 효과의 원인인지”를 가려내는 실험.

Balanced Accuracy — 답해야 할 문제와 기권해야 할 문제를 따로 채점해 평균. 한쪽만 잘하면 점수가 낮다.

BACKGROUND & MOTIVATION

멀티모달 AI는 더 똑똑해졌지만, 이미지 속 사람을 **편향**으로 판단할 위험이 커졌다

LLM·VLM의 발전으로 AI는 텍스트를 넘어 이미지·상황 맥락을 함께 이해한다. 그러나 인물·상황을 해석하는 과정에서 **성별·인종·민족** 등 사회적 단서에 기반한 편향된 판단을 내릴 수 있다.

신뢰할 수 있는 AI라면 근거가 분명할 때만 특정 답을 고르고, 정보가 부족하면 선불리 추론하지 않고 ‘판단 불가’를 택해야 한다. 본 연구의 질문:

“8B VLM이 고정관념에 휘둘리지 않고 적절히 기권하게 만들 수 있는가?
그리고 그것을 **가장 단순하게** 달성하는 방법은 무엇인가?”

두 가지 문항 유형

Ambiguous (근거 부족)

정보가 충분치 않음 → ‘판단 불가’가 정답. 고정관념으로 사람을 고르면 오답·편향.

Disambiguated (근거 명확)

본문에 근거가 있음 → 그 근거가 가리키는 답을. 과도한 기권도 오답.

두 유형을 균형 있게 평가하기 위해 **Balanced Accuracy**를 사용.

ABSTRACT

콜드스타트 없이 GRPO만으로 편향을 제거하고, 복잡도가 그 이상을 못 낸다는 것을 ablation으로 보인다

HardNeg-GRPO는 콜드스타트 SFT 없이 GRPO만으로(R1-Zero[1] 순수 RL과 동형) 편향을 제거하면서 일반화를 보존하고, 이를 최종 제출로 택한다. 나아가 더 복잡한 RL 변형이 8B에서 유의한 이득을 못 냄을 광범위한 ablation으로 관찰한다(음성결과): 포화 GRPO는 신호 부재, 콜드스타트 SFT는 일반화 이득 없이 암기 위험, 강건성 GRPO는 자신이 목표한 지표에서조차 단순한 HardNeg-GRPO를 못 이겼다. 주된 기여는 점수가 아니라 “무엇이 일반화를 살리고 죽이는가”의 분석이다.

3 TAKEAWAYS

- 01 콜드스타트 SFT가 일반화의 적. RL 단독은 일반화를 해치지 않는다.
- 02 GRPO 향상폭은 노이즈 수준. base 잠재능력 한계 내.
- 03 기여는 점수가 아니라 방법론·검증 서사. 동급이면 가장 단순한 모델.

§1 PROBLEM DEFINITION

과제 정의와 평가지표

THE TASK

이미지 + 맥락(context) + 질문 + **3지선다**에서 정답 인덱스(0/1/2)를 예측한다. 한 선택지는 ‘판단 불가’(기권). 근거가 분명하면 답을, 부족하면 사회적 고정관념에 휘둘리지 않고 기권한다.

$$\text{Balanced Accuracy} = (\text{Acc}_{\text{amb}} + \text{Acc}_{\text{dis}}) / 2$$

ambiguous · disambiguated 두 그룹 정확도의 평균. amb 여부는 비공개.

왜 단순 정확도가 아닌 Balanced Accuracy인가

한쪽 그룹만 잘 맞히는 모델을 막기 위해서다. **무조건 기권**하면 ambiguous는 다 맞지만 disambiguated는 다 틀린다. 두 그룹을 따로 채점해 평균하므로, **근거가 있을 땐 답하고 없을 땐 기권**하는 균형 잡힌 정책만 높은 점수를 받는다.

실패

한쪽 그룹만
맞히는 정책

목표

근거↔기권을
구분하는 정책

§1 CONTRIBUTIONS

본 연구의 5가지 기여

1 GRPO-only가 편향 제거 + 일반화 보존을 동시 달성 — 콜드스타트 SFT 불필요(R1-Zero 동형). 최종 제출로 선택.

2 복잡도 증가가 유의한 이득을 못 냄(음성결과) — 포화·콜드스타트·강건성 변형 모두 HardNeg를 명확히 능가하지 못함.

3 독립 held-out 외부검증(ood2: MMLU/HellaSwag/ARC-C/WinoGrande)으로 모델 선택의 견고성을 검증.

4 두 추론 레짐 ablation — 실이미지(0.9628) < 텍스트집중(1.0). 시각 채널의 기여를 실제 채점으로 측정·보고.

5 규칙기반 outcome 보상만 사용(신경망 보상모델 X) — reward hacking·비용 회피.

RELATED WORK

선행 연구 속에서 본 연구의 위치

[1] DeepSeek-R1 / R1-Zero 2501.12948

SFT 없이 순수 RL로 추론 창발. → 본 연구는 R1-Zero의 **SFT-free RL**과 논문 구조(Unsuccessful Attempts)를 차용.

[3] SFT Memorizes, RL Generalizes 2501.17161

좁은·암기형 SFT는 일반화에 해롭다. → **ColdStart 음성결과** 해석의 근거.

[6] Does Reasoning Introduce Bias? 2502.15361

추론 도입이 편향을 키울 수 있음. → **단일토큰 직답** 설계 근거.

[2] GRPO / DeepSeekMath 2402.03300

critic-free 그룹 정규화 RL. → 본 연구의 **학습 알고리즘**.

[5] BBQ Benchmark 2110.08193


편향 QA 벤치마크·편향점수($s_{\text{AMB}}/s_{\text{DIS}}$) 정의. → **과제·지표**의 출처.

본 연구의 위치

이들을 **8B** 멀티모달 **편향 과제**에 적용·검증하고, “복잡도 무이득”을 정직한 **음성결과**로 보고.

\$2 LINEAGE

실험 계보 — 탐색에서 최종 모델까지



* 코드·HF 식별자(재현성): Explore-1~3 = v1~v3 · SFT = v4 · Sat-GRPO = v5 · HardNeg-GRPO = v6 · ColdStart = v7 · Robust-A/B = v8a/v8b | 전체 코드·실험 ▶ github.com/Sungho-pk42ac/dacon-2026-skku-multimodal-ai-bias-challenge

\$2.1 SPECIFICATIONS

버전별 제작 사양 — 무엇이 갈렸나

모델 (코드)	학습 방식	rank	steps	보상	핵심 · 결과
SFT (v4)	단일토큰 LoRA SFT	32	ep 3	—	누출 제거 기반. 모든 RL 출발점
Sat-GRPO (v5)	GRPO · BBQ 전체(포화)	32	300	2종	음성 보상 분산 $\approx 0 \rightarrow$ 효과 0
HardNeg-GRPO (v6) ★	GRPO · 하드네거티브	32	400	2종	balanced 1.0 · OOD best · 최종 제출
ColdStart (v7)	콜드스타트 SFT + 추론 GRPO	64	500	추론형	음성 OOD 최저 0.84 · 암기 위험
Robust-A (v8a)	강건성 GRPO 1차	32	300	5종	음성 HardNeg와 동급, 못 넘음
Robust-B (v8b)	강건성 GRPO 2차 · 셔플씩	16	200	6종	음성 목표 지표(셔플)서도 못 이김

공통: base = Qwen3-VL-8B-Instruct · Unsloth LoRA · 언어층 학습 / 비전층 동결 · 단일토큰(0/1/2) 출력(ColdStart 예외) · 데이터는 전부 독립 공개 QA(DACON 평가셋 비파생).

Method & Reward

§3 — 왜 GRPO인가 · 보상 설계 · 학습 데이터로 강건성과 일반화를 잡는 법

💡 **쉽게 말하면** — 이 파트는 세 가지만 보면 됩니다. ① 왜 가장 단순한 방법(**GRPO**)을 골랐나, ② 상·벌점(보상)을 어떻게 설계했나, ③ “어떤 데이터로 가르쳤나”가 결국 강건성과 일반화를 만들었다.

CORE MESSAGE

콜드스타트 SFT 없이 **GRPO만으로**
편향을 제거하면서 일반화를 보존할 수 있다

DeepSeek-R1-Zero의 순수 RL과 동형 · 규칙기반 보상 2종 · 신경망 보상모델 없음

∨
GRPO-only · HardNeg-GRPO

§3 RATIONALE

왜 GRPO인가 — SFT는 암기하고, RL은 일반화한다

㉠ SFT만으로는 안 된다

좁은 BBQ를 SFT로 학습하면 정답·위치를 암기해 일반화가 무너진다(Chu et al. 2025 [3] “SFT Memorizes, RL Generalizes”). 실제로 콜드스타트 SFT(ColdStart)는 OOD 최저(0.84)를 기록했다.

㉡ 편향 완화 = ‘정책’ 학습

과제의 본질은 정답 텍스트 암기가 아니라 “근거가 있으면 커밋, 없으면 기권”이라는 결정 정책이다. 언제 커밋/기권하는가를 보상으로 가르치는 RL이 자연스럽다.

㉢ PPO가 아니라 GRPO

critic(value 모델) 없이 한 프롬프트의 **G개** 출력을 그룹 정규화해 advantage를 얻는다 → 가볍다. 규칙기반 **outcome** 보상과 결합해 신경망 보상모델 없이 reward hacking을 피한다(R1의 PRM 기각과 동일).

그래서 설계: 가벼운 단일토큰 SFT(형식만 학습) 위에 **GRPO-only** — 콜드스타트 암기 없이(R1-Zero와 동형) base의 잠재능력을 **일반화 손실 없이** 실현한다.

\$3.1-3.2 ALGORITHM + REWARD

Critic 없는 그룹 정규화 RL · 규칙기반 보상 2종

GRPO [2] (Shao et al. 2024)

한 프롬프트에 **G개 출력**을 샘플링하고, 그룹 내에서 보상을 정규화한 advantage로 정책을 갱신한다. 별도 value critic이 필요 없어 가볍다.

$$A_i = (r_i - \text{mean}(r)) / \text{std}(r)$$

+ KL 규제 · num_generations G=4

보상에 분산이 있어야 advantage가 0이 아니다 → 하드네거티브 데이터가 필수(다음 장).
💡 4개 답의 점수가 다 같으면 배울 게 없으니, 틀릴 만한 문제를 줘야 한다는 뜻.

규칙기반 보상 2종 (HardNeg)

정답 보상 (accuracy)
파싱 라벨 = 정답 인덱스

+2.0 / -0.5

형식 보상 (format)
단일토큰 0/1/2 유효(길이≤2)

+0.5 / -1.0

최종 라벨은 항상 모델 생성 텍스트 파싱 — 규칙기반 선택이 아님(대회 규칙 준수). 2종만으로 정답·형식을 동시에 겨냥.

§3.3–3.4 DESIGN RATIONALE

왜 단일토큰 직답인가 · 왜 하드네거티브인가

단일토큰 직답 — R1과의 차이

R1은 추론 체인을 유도하지만, 본 과제는 **단일토큰(0/1/2)** 직답이다. 편향 판단은 긴 추론보다 **근거 유무 판정**에 가깝고, 추론 도입이 오히려 편향을 키울 수 있다 [6].

실증: 추론형 Explore-3은 **1.65s/샘플**로 0.5s 하드제약을 3.3배 위반 → 폐기. 단일토큰은 ~0.06–0.08s.

자기진화 대신 “포화”

R1-Zero는 AIME 15.6→71.0%로 성장하지만, BBQ는 **이미 천장(1.0)**이라 끌어올릴 여지가 없다. 포화 분포 전체로 학습한 Sat-GRPO는 **보상 분산≈0 → 효과 0**이었다.

HardNeg의 처방: SFT가 틀리는 문제만 학습 → 모든 샘플이 오답 후보 → reward 신호가 살아 정책이 실제로 개선된다. 이것이 다음 장의 데이터 설계로 이어진다.

§3.5 학습 데이터 설계 ①

누출을 없애고, 위치편향을 깨다 — 강건성의 기반

누출 제거 — 모든 비교의 전제

- sha1 sample_id로 val_ids SSOT 생성 → train/val/eval에서 전역 배제 + assert.
- 시나리오 단위 dedup — 같은 상황의 amb/dis 버전이 train/val로 쪼개지지 않게.
- 효과: 부풀려진 점수(INFLATED) 제거 → 측정이 곧 진짜 성능.

초기 버전(Explore-1)의 과대평가가 바로 이 누출 때문이었고, 이를 잡는 것이 v4(SFT) 전환의 출발점이었다.

위치편향 제거 — 강건성의 시작

- 문제: BBQ는 ‘unknown’을 항상 마지막(idx 2)에 둔다 → 모델이 “애매하면 2번”이라는 위치 규칙을 외운다(의미가 아님). Hidden이 위치를 바꾸면 붕괴.
- 처방: 옵션 순서를 결정적으로 셔플 + 라벨 재매핑(train/val 모두) → 모델이 위치가 아니라 ‘기권의 의미’를 학습.



§3.5 학습 데이터 설계 ②

하드네거티브로 '학습 신호'와 '일반화'를 동시에 잡다

1 하드네거티브 채굴

학습 신호 확보

SFT가 틀린 문항만 채택 → 모든 샘플이 오답 후보 → reward 분산 유지 → gradient가 살아 정책이 개선. ↔ 포화 전체 학습(Sat-GRPO)은 분산≈0 → 효과 0.

2 일반추론 하드네거티브

일반화 확보

SIQA-CSQA-OBQA-ARC(독립 공개 QA)에서 채굴 → BBQ가 아닌 일반추론을 학습 → OOD·독립셋 일반화 상승. 이것이 HardNeg가 OOD best인 직접 원인.

3 기권 앵커

망각 방지

BBQ-ambiguous 앵커를 섞어, 일반추론을 배우는 동안에도 기권 정책을 잊지 않게 한다 → amb 사람선택오류 0.0 유지(파국적 망각 방지).

한 풀로 두 마리: '오답만'이라 신호가 살고(①), '일반추론'이라 분포 밖으로 넓어지고(②), '기권 앵커'로 핵심 정책을 지킨다(③). 규칙 준수: 전부 독립 공개 QA, DAICON 평가셋 비파생.

§3.6 DESIGN → METRIC

강건성과 일반화를 어떻게 잡았나 — 설계 선택이 곧 지표가 된다

설계 선택	노린 속성	측정 지표	HardNeg 결과
옵션 순서 셔플 + 라벨 재매핑	순서 불변 (강건성)	옵션셔플 일관성	0.9544 (동률 최고)
unknown 위치 셔플	위치 불변 (강건성)	unknown위치 일관성	1.0
일반추론 하드네거티브	분포 외 일반화	OOD / 독립 ood2	0.855 / 0.778 (best)
기관 앵커	기관 정책 보존	amb 오류 / dis 과기관	0.0 / 0.0
단일토큰 format 보상	출력 형식 강건	형식 유효율	0.962
GRPO-only (콜드스타트 X)	파국적 망각 방지	독립셋 > base	0.778 > 0.705

핵심: 강건성·일반화는 우연이 아니라 데이터 설계와 보상 설계로 의도적으로 겨냥한 결과다. 그리고 두 종류의 held-out — 공개 v8_eval(인분포+혼합OOD)과 완전 미관측 ood2(MMLU/HellaSwag/ARC-C/WinoGrande) — 로 교차검증해 “암기가 아닌 일반화”임을 확인했다.

\$3.5 REPRODUCIBILITY

학습 파이프라인 & 하이퍼파라미터

하이퍼파라미터 (HardNeg)

base	SFT (merged_v4)
LoRA rank / alpha	32 / 32 · 비전 동결
num_generations (G)	4
max_steps / lr	400 / 5e-6 cosine
temperature / seed	0.9 / 42

결정성: 제출 추론은 greedy 디코딩 → 동일 입력이면 출력이 동일. 심사위원 Hidden 재실행 시 그대로 재현된다.

하드네거티브 풀 — 5단계 절차



Results

§4-5 — 복잡도 기각 · 인분포/독립 일반화 · DACON 제출 채점

💡 **쉽게 말하면** — 결과는 세 줄입니다. ① 더 복잡한 방법 4개를 **모두 제쳤고**, ② 편향이 실제로 **0**이 되었으며, ③ **학습에 안 쓴 새 문제**에서도 점수가 올랐습니다(외운 게 아니라 진짜 실력).


\$4 ABLATION

왜 HardNeg-GRPO인가

— 복잡도가 진 자리

더 복잡한 RL 변형 4종을 모두 시험하고 ablation으로 기각했다. 어느 것도 단순한 HardNeg-GRPO를 **유의하게 넘지 못했다**(단일시드, 노이즈 수준). 복잡도가 작동조차 안 한 게 아니라, **작동했지만 HardNeg 수준으로 수렴했다**.

“SFT Memorizes, RL Generalizes.” 콜드스타트 암기는 일반화의 적, GRPO 단독은 일반화를 해치지 않는다 — Chu et al. 2025 [3]와 일치.



\$5.1 IN-DISTRIBUTION + OOD


인분포 + 혼합 OOD 결과 (v8_eval, 900문항)

지표	base(no-FT)	LLaVA-OV-7B	HardNeg ★	ColdStart	Robust-A	Robust-B
BBQ balanced acc	0.85	0.553	1.0	1.0	1.0	1.0
OOD acc	0.847	0.87	0.855	0.84	0.852	0.852
옵션셔플 일관성	0.912	0.916	0.9544	0.951	0.9544	0.952
amb 사람선택오류 ↓	0.18	0.827	0.0	0.0	0.0	0.0
dis 과기관 ↓	0.113	0.013	0.0	0.0	0.0	0.0
bias s _{AMB} ↓	0.087	0.267	0.0	0.0	0.0	0.0
출력형식 유효율	0.0	0.206	0.962	0.999	0.981	0.962
속도 (s/샘플) ↓	0.107	0.346	0.078	0.075	0.076	0.077


개선폭 입증: zero-shot VLM(LLaVA-OV)은 ambiguous 문항에서 고정관념 인물을 **83% 선택**(amb 오류 0.827). 파인튜닝 후 **0.0** → balanced 1.0은 단순 포화가 아니라 **편향 제거의 직접 증거**. HardNeg가 OOD best · 셔플 동률최고(격차는 ~2-3문항, 노이즈 수준).

\$5.2 INDEPENDENT GENERALIZATION

완전 미관측 독립셋(ood2, 600문항) — 파국적 망각 없음



옵션 셔플 일관성
순서 바뀌도 같은 답.
HardNeg **0.9544** = 동물 최고
(Robust-B 0.9522보다 높음).



BBQ 편향 제거 완료
amb 사람선택오류 **0.18→0**
s_{AMB} bias **0.087→0**
0 편향점수

독립셋 일반화 (ood2, 미관측)

+10.4% ▲
base 대비



ARC-C 0.92 · HellaSwag 0.747 · MMLU 0.767 · WinoGrande 0.68

버전별 OOD 정확도 (v8_eval)



0.855
OOD best

* 협소 BBQ 학습에도 미관측 일반추론셋 상승 → 파국적 망각 없음

§5.3 DACON SUBMISSION

실제 채점 + 시각 채널 ablation (test 8,500)

HardNeg · 텍스트집중 ★

1.0

HardNeg · 실이미지

.9628

Robust-B · 실이미지

.9643

DACON Public 리더보드 채점값 (test 라벨 비공개 → 채점이 유일 출처)

시각 채널 무용성 (ablation)

동일 HardNeg에서 텍스트집중 1.0 > 실이미지 0.9628. 실이미지는 예측을 ~10% 바꾸는데 그 변화가 점수를 깎는다 → 편향 판단은 텍스트 근거로 결정, 시각 입력은 노이즈.

HardNeg ≈ Robust-B

예측이 다른 문항은 8,500개 중 52개(0.61%)뿐 = 사실상 동일 모델. net 점수차 0.0015(노이즈) → 동급이면 더 단순한 HardNeg 확정.

정직한 경쟁가설: 텍스트집중 우위는 중립이미지 학습에 따른 분포불일치일 수 있음 → “시각 채널 본질적 무정보”로 일반화하지 않음 (§6.3).

§6 DISCUSSION

무엇이 일반화를 좌우했나 — 논의 3가지

6.1

8B + RLVR의 천장

8B에 더 복잡한 RL을 얹어도 단순 GRPO-only를 유의하게 못 넘음 → R1의 “작은 모델엔 직접 RL 추가이득 제한적”과 유사 방향(직접 대응 아님).

6.2

콜드스타트 vs GRPO-only

ColdStart는 OOD 최저(0.84) + 암기 위험. **좁은·암기형 SFT는 일반화에 해롭다**(Chu et al. 2025 [3]). R1 콜드스타트 성공과의 차이 = 데이터 다양성.

6.3

시각 채널 무용성

편향 판단이 주로 텍스트로 이뤄짐 → 텍스트집중 1.0 > 실이미지 0.9628. 단 “본질적 무정보”가 아니라 **본 파이프라인 속성**으로 한정.

핵심: 콜드스타트 SFT가 일반화의 적 · GRPO 향상은 노이즈 수준 · HardNeg의 기여는 “복잡도가 불필요함을 입증한 방법론·검증 서사”.

\$7 MODEL SELECTION

최종 모델 선택 — 6개 결정축 중 5개 best/tied

결정축	base	Robust-A	Robust-B	HardNeg
편향 balanced	0.85	1.0	1.0	1.0
편향 s _{AMB} ↓	0.087	0.0	0.0	0.0
인분포 OOD	0.847	0.852	0.852	0.855
독립 ood2	0.705	—	0.775	0.778
서플 일관성	0.912	0.954	0.952	0.954
image-invariance	0.897	—	0.972	0.975

결정 규칙

“Robust 변형이 **명확히** 증가하고 손실이 없을 때만 채택, **혼조면 HardNeg.**” → Robust-A/B 어느 것도 명확히 증가하지 못함. **혼조 → HardNeg.**

동급이면 더 단순하고 재현성 높으며 독립셋에서 미세 우위인 모델 — 입증이 아니라 보수적 선택 원칙 (Occam).

§8 UNSUCCESSFUL ATTEMPTS

음성결과 — 정직하게 보고하는 실패의 기록

×

Sat-GRPO — 포화 분포 GRPO

BBQ가 이미 포화 → 보상 분산≈0 → gradient 소실 → 항상 0. “포화된 분포엔 RL 신호가 없다.”

×

ColdStart — 콜드스타트 SFT

BBQ 암기 콜드스타트 → OOD 최저(0.84). 일반화 이득 없이 암기 위험만 추가. Chu et al. 2025 [3] 예측대로.

×

Robust-A/B — 강건성 GRPO

보상 5·6종 + 셔플짝 + 동적샘플링 [4]의 추가 복잡도가 **목표 지표(셔플)**에서조차 HardNeg를 못 이김.

×

추론형 · 신경망 보상모델

추론형(Explore-3)은 1.65s로 속도 위반 폐기. PRM/MCTS는 reward hacking·비용으로 기각.

음성결과는 버린 데이터가 아니라 “복잡도가 이 8B 과제에서 이득을 못 낸다”는 주장을 떠받치는 핵심 증거다. R1의 동명 섹션(Unsuccessful Attempts) 정신을 따른다.

§9 LIMITATIONS

연구의 한계 — 정직성 원칙

- 이미지 의존도 낮음** — 최대 한계

본 과제가 텍스트 근거 기반이라 시각 채널이 무정보. Hidden셋에 이미지 의존 문항이 많다면 취약 → 실이미지 결과(0.9628)를 정직한 멀티모달 하한으로 함께 공개.
- 단일 시드 — 통계적 유의성 미확보**

HardNeg의 대안 대비 우위(OOD·셔플·ood2 각 ~2~3문항)는 유의차로 입증되지 않음. 현재 결론은 “유의차 미검출 + 단순성 기반 보수적 선택”으로 한정.
- 보상 컴포넌트 개별 ablation 미실시**

Robust 전체가 HardNeg를 못 이긴 관찰만 있고, 5·6종 보상의 개별 기여 분해는 future work.
- R1 유추의 한계**

distillation·대형 교사모델 부재로 R1의 distill-vs-RL 측과 직접 대응 아님 → “포화·단일토큰 과제의 유사 경향”으로 한정.

FUTURE WORK

한계를 메우는 다음 단계

01 다중 시드 + 신뢰구간

단일 시드 한계 해소 — 여러 시드로 재학습해 HardNeg 우위의 통계적 유의성을 검정.

02 보상 컴포넌트 분해 ablation

Robust의 5·6종 보상을 하나씩 제거하며 어떤 컴포넌트가 효과/역효과인지 분해.

03 실이미지 학습 통제군

실이미지로 학습한 통제군과 비교해 “시각 채널 무정보 vs 분포불일치”를 분리 검증.

04 더 큰 base · distillation

8B의 천장을 넘기 위한 스케일업/종류 탐색, 그리고 이미지 의존 분포에서의 강건성 검증.

CONCLUSION

결론 — “정교함”이 아니라 “단순함”이 이겼다

콜드스타트 SFT 없이 **GRPO-only(HardNeg-GRPO)**로 편향을 제거하면서 일반화를 보존했고, 이를 최종 제출로 택했다. 더 복잡한 RL 변형 4종은 모두 이를 유의하게 넘지 못했다 — 즉 복잡도는 이 8B 편향 과제에서 비용 대비 이득이 없었다.

본 연구의 진짜 기여는 점수가 아니라, 무엇이 일반화를 살리고 죽이는지를 ablation으로 규명하고 거기서 “동급이면 가장 단순한 모델을 택한다”는 보수적 선택 원칙(Occam)을 데이터로 정당화한 것이다.

FINAL MODEL

HardNeg-GRPO

Qwen3-VL-8B + GRPO-only

1.0

텍스트집중

.9628

실이미지

5/6


결정속 best

APPENDIX A · TRAINING LOGS (W&B)

학습 로그 실측 — v4 SFT → v6 GRPO

① v4 SFT — train/loss

sft-v4-unsloth-qwen3vl · Finished

3 epochs · ~10,000 steps · lr 2e-4 cosine · loss **4.3 → 0.15** 수렴

② v6 GRPO — reward_accuracy/mean

grpo-v6-hardneg · Finished



400 steps · G=4 · 정확도 보상 0.2~0.85 활발히 진동

핵심 증거: v6 GRPO의 보상 표준편차(reward_std ≈ 0.6)가 학습 내내 유지됩니다 — 하드네거티브 풀이 reward 신호를 살려줘 정책이 실제로 갱신됨. 포화 분포로 학습한 Sat-GRPO(v5)는 분산≈0으로 신호가 죽어 효과가 0이었습니다.

APPENDIX B · FULL COMPARISON

v4 → v8b 전체 비교 — 복잡도는 늘었지만 이득은 없었다

모델 (코드)	학습 방식	balanced	OOD	셔플 일관성	판정
SFT (v4)	단일토큰 SFT	1.0	기반	기반	기준선
Sat-GRPO (v5)	+ GRPO · 포화 분포	1.0	≈기반	≈기반	효과 0 (음성)
HardNeg (v6) ★	+ GRPO · 하드네거티브	1.0	0.855	0.9544	★ PASS · 최종
ColdStart (v7)	콜드스타트 + 추론 GRPO	1.0	0.84	0.951	FAIL (음성)
Robust-A (v8a)	강건성 GRPO (rank 32)	1.0	0.852	0.9544	OOD↑ 셔플↓ (음성)
Robust-B (v8b)	강건성 GRPO (rank 16)	1.0	0.852	0.9522	PASS이나 무이득

한눈에: 모든 파인튜닝 모델이 balanced 1.0으로 포화. v5(포화)·v7(콜드스타트)·v8a/v8b(강건성)의 추가 복잡도는 **HardNeg(v6)**를 유의하게 넘지 못함 — 격차는 ~2-3문항(단일시드 노이즈). 동급이면 가장 단순한 **HardNeg(v6)**를 택한다(Occam).

THANK YOU

정교한 Robust-GRPO가, 단순한 HardNeg-GRPO를 못 이겼다

#SimplerIsBetter

#GRPO_only

#편향제거 #일반화보존

#텍스트집중_1.0

//

콜드스타트가 일반화를 돕나?

아니다. ColdStart는 OOD 최저(0.84)에 암기 위험만 더했다.

//

복잡한 보상이 점수를?

아니다. Robust-A/B는 목표 지표에서도 HardNeg를 못 이겼다(노이즈).

//

그럼 무엇을 택하나?

동급이면 가장 단순한 HardNeg-GRPO — Occam의 보수적 선택.

//

최종 제출은?

HardNeg-GRPO · 텍스트집중 1.0 / 실이미지 0.9628.

REFERENCES

참고문헌

[1] Guo, D., Yang, D., Zhang, H., *et al.* (DeepSeek-AI). **DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning**. arXiv:2501.12948, 2025. — 논문 구조 · R1-Zero · 콜드스타트 · Unsuccessful Attempts 대응

[2] Shao, Z., Wang, P., Zhu, Q., *et al.* **DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models**. arXiv:2402.03300, 2024. — GRPO 알고리즘 출처

[3] Chu, T., Zhai, Y., Yang, J., *et al.* **SFT Memorizes, RL Generalizes: A Comparative Study of Foundation Model Post-training**. ICML 2025; arXiv:2501.17161. — 콜드스타트 SFT의 일반화 손실 근거

[4] Yu, Q., Zhang, Z., Zhu, R., *et al.* (ByteDance Seed). **DAPO: An Open-Source LLM Reinforcement Learning System at Scale**. arXiv:2503.14476, 2025. — 동적 샘플링 근거

[5] Parrish, A., Chen, A., Nangia, N., *et al.* **BBQ: A Hand-Built Bias Benchmark for Question Answering**. Findings of ACL 2022; arXiv:2110.08193. — 과제 · 편향점수($s_{\text{AMB}}/s_{\text{DIS}}$) 정의

[6] Wu, X., Nian, J., Wei, T.-R., *et al.* **Does Reasoning Introduce Bias? A Study of Social Bias Evaluation and Mitigation in LLM Reasoning**. arXiv:2502.15361, 2025. — 추론 도입이 편향을 키울 수 있음

[7] Qwen Team. **Qwen3-VL Technical Report**. arXiv:2511.21631, 2025. — base 모델 (Qwen3-VL-8B-Instruct, Apache-2.0)