

2026 성균관대학교 멀티모달 AI Bias 챌린지 · 최종 제출 발표

SIMPLER IS BETTER

GRPO-only로 멀티모달 AI 편향을 완화하다

복잡도가 이득을 못 내는 8B RLVR의 한계에 대한 음성결과 기반 연구

base: Qwen3-VL-8B-Instruct (Apache-2.0) · 최종 제출 모델 **HardNeg-GRPO**

TEAM pk42ac

박성호 · 2026.06

CONTENTS

01 OVERVIEW

P.03-09

배경 · 동기

Abstract

과제 · 기여

Related Work

계보 · 사양

02 METHOD

P.10-18

왜 GRPO인가

알고리즘 · 보상

학습데이터 설계

강건성·일반화

재현 절차

03 RESULTS

P.19-23

복잡도 기각

인분포 결과

독립 일반화

DACON 채점

04 DISCUSSION

P.24-27

논의 3가지

최종 모델 선택

음성결과

한계

05 CLOSING

P.28-30

Future Work

결론

References

BACKGROUND & MOTIVATION

멀티모달 AI는 더 똑똑해졌지만, 이미지 속 사람을 **편향**으로 판단할 위험이 커졌다

LLM·VLM의 발전으로 AI는 텍스트를 넘어 이미지·상황 맥락을 함께 이해한다. 그러나 인물·상황을 해석하는 과정에서 **성별·인종·민족** 등 사회적 단서에 기반한 편향된 판단을 내릴 수 있다.

신뢰할 수 있는 AI라면 근거가 분명할 때만 특정 답을 고르고, 정보가 부족하면 선불리 추론하지 않고 ‘판단 불가’를 택해야 한다. 본 연구의 질문:

“8B VLM이 고정관념에 휘둘리지 않고 적절히 기권하게 만들 수 있는가?
그리고 그것을 **가장 단순하게** 달성하는 방법은 무엇인가?”

두 가지 문항 유형

Ambiguous (근거 부족)

정보가 충분치 않음 → ‘판단 불가’가 정답. 고정관념으로 사람을 고르면 오답·편향.

Disambiguated (근거 명확)

본문에 근거가 있음 → 그 근거가 가리키는 답을. 과도한 기권도 오답.

두 유형을 균형 있게 평가하기 위해 **Balanced Accuracy**를 사용.

ABSTRACT

콜드스타트 없이 GRPO만으로 편향을 제거하고, 복잡도가 그 이상을 못 낸다는 것을 ablation으로 보인다

HardNeg-GRPO는 콜드스타트 SFT 없이 GRPO만으로(R1-Zero 순수 RL과 동형) 편향을 제거하면서 일반화를 보존하고, 이를 최종 제출로 택한다. 나아가 더 복잡한 RL 변형이 8B에서 유의한 이득을 못 냄을 광범위한 ablation으로 관찰한다(음성결과): 포화 GRPO는 신호 부재, 콜드스타트 SFT는 일반화 이득 없이 암기 위험, 강건성 GRPO는 자신이 목표한 지표에서조차 단순한 HardNeg-GRPO를 못 이겼다. 주된 기여는 점수가 아니라 “무엇이 일반화를 살리고 죽이는가”의 분석이다.

3 TAKEAWAYS

- 01 콜드스타트 SFT가 일반화의 적. RL 단독은 일반화를 해치지 않는다.
- 02 GRPO 향상폭은 노이즈 수준. base 잠재능력 한계 내.
- 03 기여는 점수가 아니라 방법론·검증 서사. 동급이면 가장 단순한 모델.

§1 PROBLEM DEFINITION

과제 정의와 평가지표

THE TASK

이미지 + 맥락(context) + 질문 + **3지선다**에서 정답 인덱스(0/1/2)를 예측한다. 한 선택지는 ‘판단 불가’(기권). 근거가 분명하면 답을, 부족하면 사회적 고정관념에 휘둘리지 않고 기권한다.

$$\text{Balanced Accuracy} = (\text{Acc}_{\text{amb}} + \text{Acc}_{\text{dis}}) / 2$$

ambiguous · disambiguated 두 그룹 정확도의 평균. amb 여부는 비공개.

왜 단순 정확도가 아닌 Balanced Accuracy인가

한쪽 그룹만 잘 맞는 모델을 막기 위해서다. **무조건 기권**하면 ambiguous는 다 맞지만 disambiguated는 다 틀린다. 두 그룹을 따로 채점해 평균하므로, **근거가 있을 땐 답하고 없을 땐 기권**하는 균형 잡힌 정책만 높은 점수를 받는다.

실패

한쪽 그룹만
맞히는 정책

목표

근거↔기권을
구분하는 정책

§1 CONTRIBUTIONS

본 연구의 5가지 기여

- 1** GRPO-only가 편향 제거 + 일반화 보존을 동시 달성 — 콜드스타트 SFT 불필요(R1-Zero 동형). 최종 제출로 선택.
- 2** 복잡도 증가가 유의한 이득을 못 냄(음성결과) — 포화·콜드스타트·강건성 변형 모두 HardNeg를 명확히 능가하지 못함.
- 3** 독립 held-out 외부검증(ood2: MMLU/HellaSwag/ARC-C/WinoGrande)으로 모델 선택의 견고성을 검증.
- 4** 두 추론 레짐 ablation — 실이미지(0.9628) < 텍스트집중(1.0). 시각 채널의 기여를 실제 채점으로 측정·보고.
- 5** 규칙기반 outcome 보상만 사용(신경망 보상모델 X) — reward hacking·비용 회피.

RELATED WORK

선행 연구 속에서 본 연구의 위치

DeepSeek-R1 / R1-Zero 2501.12948

SFT 없이 순수 RL로 추론 창발. → 본 연구는 R1-Zero의 **SFT-free RL**과 논문 구조(Unsuccessful Attempts)를 차용.

SFT Memorizes, RL Generalizes 2501.17161

좁은·암기형 SFT는 일반화에 해롭다. → **ColdStart 음성결과** 해석의 근거.

Does Reasoning Introduce Bias? 2502.15361

추론 도입이 편향을 키울 수 있음. → **단일토큰** 직답 설계 근거.

GRPO / DeepSeekMath 2402.03300

critic-free 그룹 정규화 RL. → 본 연구의 **학습 알고리즘**.

BBQ Benchmark 2110.08193


편향 QA 벤치마크·편향점수($s_{\text{AMB}}/s_{\text{DIS}}$) 정의. → **과제·지표**의 출처.

본 연구의 위치

이들을 **8B** 멀티모달 **편향 과제**에 적용·검증하고, “복잡도 무이득”을 정직한 **음성결과**로 보고.

\$2 LINEAGE

실험 계보 — 탐색에서 최종 모델까지



* 코드·HF 식별자(재현성): Explore-1~3 = v1~v3 · SFT = v4 · Sat-GRPO = v5 · **HardNeg-GRPO = v6** · ColdStart = v7 · Robust-A/B = v8a/v8b

\$2.1 SPECIFICATIONS

버전별 제작 사양 — 무엇이 갈렸나

모델 (코드)	학습 방식	rank	steps	보상	핵심 · 결과
SFT (v4)	단일토큰 LoRA SFT	32	ep 3	—	누출 제거 기반. 모든 RL 출발점
Sat-GRPO (v5)	GRPO · BBQ 전체(포화)	32	300	2종	음성 보상 분산 $\approx 0 \rightarrow$ 효과 0
HardNeg-GRPO (v6) ★	GRPO · 하드네거티브	32	400	2종	balanced 1.0 · OOD best · 최종 제출
ColdStart (v7)	콜드스타트 SFT + 추론 GRPO	64	500	추론형	음성 OOD 최저 0.84 · 암기 위험
Robust-A (v8a)	강건성 GRPO 1차	32	300	5종	음성 HardNeg와 동급, 못 넘음
Robust-B (v8b)	강건성 GRPO 2차 · 셔플씩	16	200	6종	음성 목표 지표(셔플)서도 못 이김

공통: base = Qwen3-VL-8B-Instruct · Unsloth LoRA · 언어층 학습 / 비전층 동결 · 단일토큰(0/1/2) 출력(ColdStart 예외) · 데이터는 전부 독립 공개 QA(DACON 평가셋 비파생).

Method & Reward

§3 — 왜 GRPO인가 · 보상 설계 · 학습 데이터로 강건성과 일반화를 잡는 법

CORE MESSAGE

콜드스타트 SFT 없이 **GRPO만으로**
편향을 제거하면서 일반화를 보존할 수 있다

DeepSeek-R1-Zero의 순수 RL과 동형 · 규칙기반 보상 2종 · 신경망 보상모델 없음

∨
GRPO-only · HardNeg-GRPO

§3 RATIONALE

왜 GRPO인가 — SFT는 암기하고, RL은 일반화한다

㉠ SFT만으로는 안 된다

좁은 BBQ를 SFT로 학습하면 정답·위치를 암기해 일반화가 무너진다(Chu 2025 “SFT Memorizes, RL Generalizes”). 실제로 콜드스타트 SFT(ColdStart)는 OOD 최저(0.84)를 기록했다.

㉡ 편향 완화 = ‘정책’ 학습

과제의 본질은 정답 텍스트 암기가 아니라 “근거가 있으면 커밋, 없으면 기권”이라는 결정 정책이다. 언제 커밋/기권하는가를 보상으로 가르치는 RL이 자연스럽다.

㉢ PPO가 아니라 GRPO

critic(value 모델) 없이 한 프롬프트의 **G개** 출력을 그룹 정규화해 advantage를 얻는다 → 가볍다. 규칙기반 **outcome** 보상과 결합해 신경망 보상모델 없이 reward hacking을 피한다(R1의 PRM 기각과 동일).

그래서 설계: 가벼운 단일토큰 SFT(형식만 학습) 위에 **GRPO-only** — 콜드스타트 암기 없이(R1-Zero와 동형) base의 잠재능력을 일반화 손실 없이 실현한다.

\$3.1-3.2 ALGORITHM + REWARD

Critic 없는 그룹 정규화 RL · 규칙기반 보상 2종

GRPO (Shao et al. 2024)

한 프롬프트에 **G개 출력**을 샘플링하고, 그룹 내에서 보상을 정규화한 advantage로 정책을 갱신한다. 별도 value critic이 필요 없어 가볍다.

$$A_i = (r_i - \text{mean}(r)) / \text{std}(r)$$

+ KL 규제 · num_generations G=4

보상에 분산이 있어야 advantage가 0이 아니다 → 하드네거티브 데이터가 필수(다음 장).

규칙기반 보상 2종 (HardNeg)

정답 보상 (accuracy)
파싱 라벨 = 정답 인덱스

+2.0 / -0.5

형식 보상 (format)
단일토큰 0/1/2 유효(길이≤2)

+0.5 / -1.0

최종 라벨은 항상 모델 생성 텍스트 파싱 — 규칙기반 선택이 아님(대회 규칙 준수). 2종만으로 정답·형식을 동시에 겨냥.

§3.3–3.4 DESIGN RATIONALE

왜 단일토큰 직답인가 · 왜 하드네거티브인가

단일토큰 직답 — R1과의 차이

R1은 추론 체인을 유도하지만, 본 과제는 **단일토큰(0/1/2)** 직답이다. 편향 판단은 긴 추론보다 **근거 유무 판정**에 가깝고, 추론 도입이 오히려 편향을 키울 수 있다(2502.15361).

실증: 추론형 Explore-3은 **1.65s/샘플**로 0.5s 하드제약을 3.3배 위반 → 폐기. 단일토큰은 ~0.06–0.08s.

자기진화 대신 “포화”

R1-Zero는 AIME 15.6→71.0%로 성장하지만, BBQ는 **이미 천장(1.0)**이라 끌어올릴 여지가 없다. 포화 분포 전체로 학습한 Sat-GRPO는 **보상 분산≈0 → 효과 0**이었다.

HardNeg의 처방: SFT가 틀리는 문제만 학습 → 모든 샘플이 오답 후보 → reward 신호가 살아 정책이 실제로 개선된다. 이것이 다음 장의 데이터 설계로 이어진다.

§3.5 학습 데이터 설계 ①

누출을 없애고, 위치편향을 깨다 — 강건성의 기반

누출 제거 — 모든 비교의 전제

- sha1 sample_id로 val_ids SSOT 생성 → train/val/eval에서 전역 배제 + assert.
- 시나리오 단위 dedup — 같은 상황의 amb/dis 버전이 train/val로 쪼개지지 않게.
- 효과: 부풀려진 점수(INFLATED) 제거 → 측정이 곧 진짜 성능.

초기 버전(Explore-1)의 과대평가가 바로 이 누출 때문이었고, 이를 잡는 것이 v4(SFT) 전환의 출발점이었다.

위치편향 제거 — 강건성의 시작

- 문제: BBQ는 ‘unknown’을 항상 마지막(idx 2)에 둔다 → 모델이 “애매하면 2번”이라는 위치 규칙을 외운다(의미가 아님). Hidden이 위치를 바꾸면 붕괴.
- 처방: 옵션 순서를 결정적으로 셔플 + 라벨 재매핑(train/val 모두) → 모델이 위치가 아니라 ‘기권의 의미’를 학습.



§3.5 학습 데이터 설계 ②

하드네거티브로 '학습 신호'와 '일반화'를 동시에 잡다

1 하드네거티브 채굴

학습 신호 확보

SFT가 틀린 문항만 채택 → 모든 샘플이 오답 후보 → reward 분산 유지 → gradient가 살아 정책이 개선. ↔ 포화 전체 학습(Sat-GRPO)은 분산≈0 → 효과 0.

2 일반추론 하드네거티브

일반화 확보

SIQA-CSQA-OBQA-ARC(독립 공개 QA)에서 채굴 → BBQ가 아닌 일반추론을 학습 → OOD·독립셋 일반화 상승. 이것이 HardNeg가 OOD best인 직접 원인.

3 기권 앵커

망각 방지

BBQ-ambiguous 앵커를 섞어, 일반추론을 배우는 동안에도 기권 정책을 잊지 않게 한다 → amb 사람선택오류 0.0 유지(파국적 망각 방지).

한 풀로 두 마리: '오답만'이라 신호가 살고(①), '일반추론'이라 분포 밖으로 넓어지고(②), '기권 앵커'로 핵심 정책을 지킨다(③). 규칙 준수: 전부 독립 공개 QA, DAICON 평가셋 비파생.

§3.6 DESIGN → METRIC

강건성과 일반화를 어떻게 잡았나 — 설계 선택이 곧 지표가 된다

설계 선택	노린 속성	측정 지표	HardNeg 결과
옵션 순서 셔플 + 라벨 재매핑	순서 불변 (강건성)	옵션셔플 일관성	0.9544 (동률 최고)
unknown 위치 셔플	위치 불변 (강건성)	unknown위치 일관성	1.0
일반추론 하드네거티브	분포 외 일반화	OOD / 독립 ood2	0.855 / 0.778 (best)
기권 앵커	기권 정책 보존	amb 오류 / dis 과기권	0.0 / 0.0
단일토큰 format 보상	출력 형식 강건	형식 유효율	0.962
GRPO-only (콜드스타트 X)	파국적 망각 방지	독립셋 > base	0.778 > 0.705

핵심: 강건성·일반화는 우연이 아니라 데이터 설계와 보상 설계로 의도적으로 겨냥한 결과다. 그리고 두 종류의 held-out — 공개 v8_eval(인분포+혼합OOD)과 완전 미관측 ood2(MMLU/HellaSwag/ARC-C/WinoGrande) — 로 교차검증해 “암기가 아닌 일반화”임을 확인했다.

\$3.5 REPRODUCIBILITY

학습 파이프라인 & 하이퍼파라미터

하이퍼파라미터 (HardNeg)

base	SFT (merged_v4)
LoRA rank / alpha	32 / 32 · 비전 동결
num_generations (G)	4
max_steps / lr	400 / 5e-6 cosine
temperature / seed	0.9 / 42

결정성: 제출 추론은 greedy 디코딩 → 동일 입력이면 출력이 동일. 심사위원 Hidden 재실행 시 그대로 재현된다.

하드네거티브 풀 — 5단계 절차



Results

§4-5 — 복잡도 기각 · 인분포/독립 일반화 · DACON 제출 채점


\$4 ABLATION

왜 HardNeg-GRPO인가

— 복잡도가 진 자리

더 복잡한 RL 변형 4종을 모두 시험하고 ablation으로 기각했다. 어느 것도 단순한 HardNeg-GRPO를 **유의하게 넘지 못했다**(단일시드, 노이즈 수준). 복잡도가 작동조차 안 한 게 아니라, **작동했지만 HardNeg 수준으로 수렴했다**.

“SFT Memorizes, RL Generalizes.” 콜드스타트 암기는 일반화의 적, GRPO 단독은 일반화를 해치지 않는다 — Chu 2025와 일치.



\$5.1 IN-DISTRIBUTION + OOD


인분포 + 혼합 OOD 결과 (v8_eval, 900문항)

지표	base(no-FT)	LLaVA-OV-7B	HardNeg ★	ColdStart	Robust-A	Robust-B
BBQ balanced acc	0.85	0.553	1.0	1.0	1.0	1.0
OOD acc	0.847	0.87	0.855	0.84	0.852	0.852
옵션셔플 일관성	0.912	0.916	0.9544	0.951	0.9544	0.952
amb 사람선택오류 ↓	0.18	0.827	0.0	0.0	0.0	0.0
dis 과기관 ↓	0.113	0.013	0.0	0.0	0.0	0.0
bias s _{AMB} ↓	0.087	0.267	0.0	0.0	0.0	0.0
출력형식 유효율	0.0	0.206	0.962	0.999	0.981	0.962
속도 (s/샘플) ↓	0.107	0.346	0.078	0.075	0.076	0.077

개선폭 입증: zero-shot VLM(LLaVA-OV)은 ambiguous 문항에서 고정관념 인물을 **83% 선택**(amb 오류 0.827). 파인튜닝 후 **0.0** → balanced 1.0은 단순 포화가 아니라 **편향 제거의 직접 증거**. HardNeg가 OOD best · 셔플 동률최고(격차는 ~2-3문항, 노이즈 수준).

\$5.2 INDEPENDENT GENERALIZATION


완전 미관측 독립셋(ood2, 600문항) — 파국적 망각 없음



0.954
shuffle

옵션 셔플 일관성

순서 바뀌도 같은 답.
HardNeg **0.9544** = 동물 최고
(Robust-B 0.9522보다 높음).



1.0
balanced acc

BBQ 편향 제거 완료

amb 사람선택오류 **0.18→0**
s_{AMB} bias **0.087→0**

0 편향점수

독립셋 일반화 (ood2, 미관측)

+10.4% ▲
base 대비

base		0.705
HardNeg		0.778

ARC-C 0.92 · HellaSwag 0.747 · MMLU 0.767 · WinoGrande 0.68

버전별 OOD 정확도 (v8_eval)

base		.847
Robust-A		.852
Robust-B		.852
HardNeg		.855

0.855
OOD best

* 협소 BBQ 학습에도 미관측 일반추론셋 상승 → 파국적 망각 없음

§5.3 DACON SUBMISSION

실제 채점 + 시각 채널 ablation (test 8,500)

HardNeg · 텍스트집중 ★

1.0

HardNeg · 실이미지

.9628

Robust-B · 실이미지

.9643

DACON Public 리더보드 채점값 (test 라벨 비공개 → 채점이 유일 출처)

시각 채널 무용성 (ablation)

동일 HardNeg에서 텍스트집중 1.0 > 실이미지 0.9628. 실이미지는 예측을 ~10% 바꾸는데 그 변화가 점수를 깎는다 → 편향 판단은 텍스트 근거로 결정, 시각 입력은 노이즈.

HardNeg ≈ Robust-B

예측이 다른 문항은 8,500개 중 52개(0.61%)뿐 = 사실상 동일 모델. net 점수차 0.0015(노이즈) → 동급이면 더 단순한 HardNeg 확정.

정직한 경쟁가설: 텍스트집중 우위는 중립이미지 학습에 따른 분포불일치일 수 있음 → “시각 채널 본질적 무정보”로 일반화하지 않음 (§6.3).

§6 DISCUSSION

무엇이 일반화를 좌우했나 — 논의 3가지

6.1

8B + RLVR의 천장

8B에 더 복잡한 RL을 얹어도 단순 GRPO-only를 유의하게 못 넘음 → R1의 “작은 모델엔 직접 RL 추가이득 제한적”과 유사 방향(직접 대응 아님).

6.2

콜드스타트 vs GRPO-only

ColdStart는 OOD 최저(0.84) + 암기 위험. 좁은·암기형 SFT는 일반화에 해롭다(Chu 2025). R1 콜드스타트 성공과의 차이 = 데이터 다양성.

6.3

시각 채널 무용성

편향 판단이 주로 텍스트로 이뤄짐 → 텍스트집중 1.0 > 실이미지 0.9628. 단 “본질적 무정보”가 아니라 본 파이프라인 속성으로 한정.

핵심: 콜드스타트 SFT가 일반화의 적 · GRPO 향상은 노이즈 수준 · HardNeg의 기여는 “복잡도가 불필요함을 입증한 방법론·검증 서사”.

\$7 MODEL SELECTION

최종 모델 선택 — 6개 결정축 중 5개 best/tied

결정축	base	Robust-A	Robust-B	HardNeg
편향 balanced	0.85	1.0	1.0	1.0
편향 s _{AMB} ↓	0.087	0.0	0.0	0.0
인분포 OOD	0.847	0.852	0.852	0.855
독립 ood2	0.705	—	0.775	0.778
서플 일관성	0.912	0.954	0.952	0.954
image-invariance	0.897	—	0.972	0.975

결정 규칙

“Robust 변형이 **명확히** 증가하고 손실이 없을 때만 채택, **혼조면 HardNeg.**” → Robust-A/B 어느 것도 명확히 증가하지 못함. **혼조 → HardNeg.**

동급이면 더 **단순하고 재현성 높으며 독립셋에서 미세 우위인 모델** — 입증이 아니라 **보수적 선택 원칙** (Occam).

§8 UNSUCCESSFUL ATTEMPTS

음성결과 — 정직하게 보고하는 실패의 기록

×

Sat-GRPO — 포화 분포 GRPO

BBQ가 이미 포화 → 보상 분산≈0 → gradient 소실 → 항상 0. “포화된 분포엔 RL 신호가 없다.”

×

ColdStart — 콜드스타트 SFT

BBQ 암기 콜드스타트 → OOD 최저(0.84). 일반화 이득 없이 암기 위험만 추가. Chu 2025 예측대로.

×

Robust-A/B — 강건성 GRPO

보상 5·6종 + 셔플짝 + 동적샘플링의 추가 복잡도가 **목표 지표(셔플)**에서조차 HardNeg를 못 이김.

×

추론형 · 신경망 보상모델

추론형(Explore-3)은 1.65s로 속도 위반 폐기. PRM/MCTS는 reward hacking·비용으로 기각.

음성결과는 버린 데이터가 아니라 “복잡도가 이 8B 과제에서 이득을 못 낸다”는 주장을 떠받치는 핵심 증거다. R1의 동명 섹션(Unsuccessful Attempts) 정신을 따른다.

§9 LIMITATIONS

연구의 한계 — 정직성 원칙

이미지 의존도 낮음 — 최대 한계

본 과제가 텍스트 근거 기반이라 시각 채널이 무정보. Hidden셋에 이미지 의존 문항이 많다면 취약 → 실이미지 결과(0.9628)를 정직한 멀티모달 하한으로 함께 공개.

단일 시드 — 통계적 유의성 미확보

HardNeg의 대안 대비 우위(OOD·셔플·ood2 각 ~2~3문항)는 유의차로 입증되지 않음. 현재 결론은 “유의차 미검출 + 단순성 기반 보수적 선택”으로 한정.

보상 컴포넌트 개별 ablation 미실시

Robust 전체가 HardNeg를 못 이긴 관찰만 있고, 5·6종 보상의 개별 기여 분해는 future work.

R1 유추의 한계

distillation·대형 교사모델 부재로 R1의 distill-vs-RL 측과 직접 대응 아님 → “포화·단일토큰 과제의 유사 경향”으로 한정.

FUTURE WORK

한계를 메우는 다음 단계

01 다중 시드 + 신뢰구간

단일 시드 한계 해소 — 여러 시드로 재학습해 HardNeg 우위의 통계적 유의성을 검정.

02 보상 컴포넌트 분해 ablation

Robust의 5·6종 보상을 하나씩 제거하며 어떤 컴포넌트가 효과/역효과인지 분해.

03 실이미지 학습 통제군

실이미지로 학습한 통제군과 비교해 “시각 채널 무정보 vs 분포불일치”를 분리 검증.

04 더 큰 base · distillation

8B의 천장을 넘기 위한 스케일업/종류 탐색, 그리고 이미지 의존 분포에서의 강건성 검증.

CONCLUSION

결론 — “정교함”이 아니라 “단순함”이 이겼다

콜드스타트 SFT 없이 **GRPO-only(HardNeg-GRPO)**로 편향을 제거하면서 일반화를 보존했고, 이를 최종 제출로 택했다. 더 복잡한 RL 변형 4종은 모두 이를 유의하게 넘지 못했다 — 즉 복잡도는 이 8B 편향 과제에서 비용 대비 이득이 없었다.

본 연구의 진짜 기여는 점수가 아니라, 무엇이 일반화를 살리고 죽이는지를 ablation으로 규명하고 거기서 “동급이면 가장 단순한 모델을 택한다”는 보수적 선택 원칙(Occam)을 데이터로 정당화한 것이다.

FINAL MODEL

HardNeg-GRPO

Qwen3-VL-8B + GRPO-only

1.0

텍스트집중

.9628

실이미지

5/6

결정속 best

THANK YOU

정교한 Robust-GRPO가, 단순한 HardNeg-GRPO를 못 이겼다

#SimplerIsBetter

#GRPO_only

#편향제거 #일반화보존

#텍스트집중_1.0

//

콜드스타트가 일반화를 돕나?

아니다. ColdStart는 OOD 최저(0.84)에 암기 위험만 더했다.

//

복잡한 보상이 점수를?

아니다. Robust-A/B는 목표 지표에서도 HardNeg를 못 이겼다(노이즈).

//

그럼 무엇을 택하나?

동급이면 가장 단순한 HardNeg-GRPO — Occam의 보수적 선택.

//

최종 제출은?

HardNeg-GRPO · 텍스트집중 1.0 / 실이미지 0.9628.