

2026 성균관대학교 멀티모달 AI Bias 챌린지 · 최종 제출 발표

# SIMPLER IS BETTER

GRPO-only로 멀티모달 AI 편향을 완화하다

복잡도가 이득을 못 내는 8B RLVR의 한계에 대한 음성결과 기반 연구

base: Qwen3-VL-8B-Instruct[7] (Apache-2.0) · 최종 제출 모델 **HardNeg-GRPO**

**TEAM** pk42ac

박성호 · 2026.06

# CONTENTS

## 01 OVERVIEW

P.03-09

배경 · 동기

Abstract

과제 · 기여

Related Work

계보 · 사양

## 02 METHOD

P.10-18

왜 GRPO인가

알고리즘 · 보상

학습데이터 설계

강건성·일반화

재현 절차

## 03 RESULTS

P.19-23

복잡도 기각

인분포 결과

독립 일반화

DACON 채점

## 04 DISCUSSION

P.24-27

논의 3가지

최종 모델 선택

음성결과

한계

## 05 CLOSING

P.28-33

Future Work · 결론

학습로그 · 비교표

References

## BACKGROUND &amp; MOTIVATION

# 멀티모달 AI는 더 똑똑해졌지만, 이미지 속 사람을 **편향**으로 판단할 위험이 커졌다

LLM·VLM의 발전으로 AI는 텍스트를 넘어 이미지·상황 맥락을 함께 이해한다. 그러나 인물·상황을 해석하는 과정에서 **성별·인종·민족** 등 사회적 단서에 기반한 편향된 판단을 내릴 수 있다.

신뢰할 수 있는 AI라면 근거가 분명할 때만 특정 답을 고르고, 정보가 부족하면 선불리 추론하지 않고 ‘판단 불가’를 택해야 한다. 본 연구의 질문:

“8B VLM이 고정관념에 휘둘리지 않고 적절히 기권하게 만들 수 있는가?  
그리고 그것을 **가장 단순하게** 달성하는 방법은 무엇인가?”

## 두 가지 문항 유형

### Ambiguous (근거 부족)

정보가 충분치 않음 → ‘판단 불가’가 정답. 고정관념으로 사람을 고르면 오답·편향.

### Disambiguated (근거 명확)

본문에 근거가 있음 → 그 근거가 가리키는 답을. 과도한 기권도 오답.

두 유형을 균형 있게 평가하기 위해 **Balanced Accuracy**를 사용.

## ABSTRACT

# 콜드스타트 없이 GRPO만으로 편향을 제거하고, 복잡도가 그 이상을 못 낸다는 것을 ablation으로 보인다

**HardNeg-GRPO**는 콜드스타트 SFT 없이 GRPO만으로(R1-Zero[1] 순수 RL과 동형) 편향을 제거하면서 일반화를 보존하고, 이를 최종 제출로 택한다. 나아가 더 복잡한 RL 변형이 8B에서 유의한 이득을 못 냄을 광범위한 ablation으로 관찰한다(음성결과): 포화 GRPO는 신호 부재, 콜드스타트 SFT는 일반화 이득 없이 암기 위험, 강건성 GRPO는 자신이 목표한 지표에서조차 단순한 HardNeg-GRPO를 못 이겼다. 주된 기여는 점수가 아니라 “무엇이 일반화를 살리고 죽이는가”의 분석이다.

## 3 TAKEAWAYS

- 01 콜드스타트 SFT가 일반화의 적. RL 단독은 일반화를 해치지 않는다.
- 02 GRPO 향상폭은 노이즈 수준. base 잠재능력 한계 내.
- 03 기여는 점수가 아니라 방법론·검증 서사. 동급이면 가장 단순한 모델.

§1 PROBLEM DEFINITION

# 과제 정의와 평가지표

## THE TASK

이미지 + 맥락(context) + 질문 + **3지선다**에서 정답 인덱스(0/1/2)를 예측한다. 한 선택지는 ‘판단 불가’(기권). 근거가 분명하면 답을, 부족하면 사회적 고정관념에 휘둘리지 않고 기권한다.

$$\text{Balanced Accuracy} = ( \text{Acc}_{\text{amb}} + \text{Acc}_{\text{dis}} ) / 2$$

ambiguous · disambiguated 두 그룹 정확도의 평균. amb 여부는 비공개.

## 왜 단순 정확도가 아닌 Balanced Accuracy인가

한쪽 그룹만 잘 맞히는 모델을 막기 위해서다. **무조건 기권**하면 ambiguous는 다 맞지만 disambiguated는 다 틀린다. 두 그룹을 따로 채점해 평균하므로, **근거가 있을 땐 답하고 없을 땐 기권**하는 균형 잡힌 정책만 높은 점수를 받는다.

실패

한쪽 그룹만  
맞히는 정책

목표

근거↔기권을  
구분하는 정책

## §1 CONTRIBUTIONS

# 본 연구의 5가지 기여

**1** GRPO-only가 편향 제거 + 일반화 보존을 동시 달성 — 콜드스타트 SFT 불필요(R1-Zero 동형). 최종 제출로 선택.

**2** 복잡도 증가가 유의한 이득을 못 냄(음성결과) — 포화·콜드스타트·강건성 변형 모두 HardNeg를 명확히 능가하지 못함.

**3** 독립 held-out 외부검증(ood2: MMLU/HellaSwag/ARC-C/WinoGrande)으로 모델 선택의 견고성을 검증.

**4** 두 추론 레짐 ablation — 실이미지(0.9628) < 텍스트집중(1.0). 시각 채널의 기여를 실제 채점으로 측정·보고.

**5** 규칙기반 outcome 보상만 사용(신경망 보상모델 X) — reward hacking·비용 회피.

RELATED WORK

# 선행 연구 속에서 본 연구의 위치

[1] DeepSeek-R1 / R1-Zero 2501.12948

SFT 없이 순수 RL로 추론 창발. → 본 연구는 R1-Zero의 **SFT-free RL**과 논문 구조(Unsuccessful Attempts)를 차용.

[3] SFT Memorizes, RL Generalizes 2501.17161

좁은·암기형 SFT는 일반화에 해롭다. → **ColdStart 음성결과** 해석의 근거.

[6] Does Reasoning Introduce Bias? 2502.15361

추론 도입이 편향을 키울 수 있음. → **단일토큰 직답** 설계 근거.

[2] GRPO / DeepSeekMath 2402.03300

critic-free 그룹 정규화 RL. → 본 연구의 **학습 알고리즘**.

[5] BBQ Benchmark 2110.08193


편향 QA 벤치마크·편향점수( $s_{\text{AMB}}/s_{\text{DIS}}$ ) 정의. → **과제·지표**의 출처.

본 연구의 위치

이들을 **8B** 멀티모달 **편향 과제**에 적용·검증하고, “복잡도 무이득”을 정직한 **음성결과**로 보고.

\$2 LINEAGE

실험 계보 — 탐색에서 최종 모델까지



\* 코드·HF 식별자(재현성): Explore-1~3 = v1~v3 · SFT = v4 · Sat-GRPO = v5 · **HardNeg-GRPO = v6** · ColdStart = v7 · Robust-A/B = v8a/v8b



\$2.1 SPECIFICATIONS

# 버전별 제작 사양 — 무엇이 갈렸나

| 모델 (코드)             | 학습 방식               | rank | steps | 보상  | 핵심 · 결과                               |
|---------------------|---------------------|------|-------|-----|---------------------------------------|
| SFT (v4)            | 단일토큰 LoRA SFT       | 32   | ep 3  | —   | 누출 제거 기반. 모든 RL 출발점                   |
| Sat-GRPO (v5)       | GRPO · BBQ 전체(포화)   | 32   | 300   | 2종  | 음성 보상 분산 $\approx 0 \rightarrow$ 효과 0 |
| HardNeg-GRPO (v6) ★ | GRPO · 하드네거티브       | 32   | 400   | 2종  | balanced 1.0 · OOD best · 최종 제출       |
| ColdStart (v7)      | 콜드스타트 SFT + 추론 GRPO | 64   | 500   | 추론형 | 음성 OOD 최저 0.84 · 암기 위험                |
| Robust-A (v8a)      | 강건성 GRPO 1차         | 32   | 300   | 5종  | 음성 HardNeg와 동급, 못 넘음                  |
| Robust-B (v8b)      | 강건성 GRPO 2차 · 셔플씩   | 16   | 200   | 6종  | 음성 목표 지표(셔플)서도 못 이김                   |

공통: base = Qwen3-VL-8B-Instruct · Unsloth LoRA · 언어층 학습 / 비전층 동결 · 단일토큰(0/1/2) 출력(ColdStart 예외) · 데이터는 전부 독립 공개 QA(DACON 평가셋 비파생).

# Method & Reward

§3 — 왜 GRPO인가 · 보상 설계 · 학습 데이터로 강건성과 일반화를 잡는 법

## CORE MESSAGE

콜드스타트 SFT 없이 **GRPO만으로**  
편향을 제거하면서 일반화를 보존할 수 있다

DeepSeek-R1-Zero의 순수 RL과 동형 · 규칙기반 보상 2종 · 신경망 보상모델 없음

∨  
GRPO-only · HardNeg-GRPO

## §3 RATIONALE

# 왜 GRPO인가 — SFT는 암기하고, RL은 일반화한다

## ㉠ SFT만으로는 안 된다

좁은 BBQ를 SFT로 학습하면 정답·위치를 암기해 일반화가 무너진다(Chu et al. 2025 [3] “SFT Memorizes, RL Generalizes”). 실제로 콜드스타트 SFT(ColdStart)는 OOD 최저(0.84)를 기록했다.

## ㉡ 편향 완화 = ‘정책’ 학습

과제의 본질은 정답 텍스트 암기가 아니라 “근거가 있으면 커밋, 없으면 기권”이라는 결정 정책이다. 언제 커밋/기권하는가를 보상으로 가르치는 RL이 자연스럽다.

## ㉢ PPO가 아니라 GRPO

critic(value 모델) 없이 한 프롬프트의 **G개** 출력을 그룹 정규화해 advantage를 얻는다 → 가볍다. 규칙기반 **outcome** 보상과 결합해 신경망 보상모델 없이 reward hacking을 피한다(R1의 PRM 기각과 동일).

그래서 설계: 가벼운 단일토큰 SFT(형식만 학습) 위에 **GRPO-only** — 콜드스타트 암기 없이(R1-Zero와 동형) base의 잠재능력을 일반화 손실 없이 실현한다.

\$3.1-3.2 ALGORITHM + REWARD

# Critic 없는 그룹 정규화 RL · 규칙기반 보상 2종

GRPO [2] (Shao et al. 2024)

한 프롬프트에 **G개 출력**을 샘플링하고, 그룹 내에서 보상을 정규화한 advantage로 정책을 갱신한다. 별도 value critic이 필요 없어 가볍다.

$$A_i = ( r_i - \text{mean}(r) ) / \text{std}(r)$$

+ KL 규제 · num\_generations G=4

보상에 분산이 있어야 advantage가 0이 아니다 → 하드네거티브 데이터가 필수(다음 장).

규칙기반 보상 2종 (HardNeg)

정답 보상 (accuracy)

파싱 라벨 = 정답 인덱스

+2.0 / -0.5

형식 보상 (format)

단일토큰 0/1/2 유효(길이≤2)

+0.5 / -1.0

최종 라벨은 항상 모델 생성 텍스트 파싱 — 규칙기반 선택이 아님(대회 규칙 준수). 2종만으로 정답·형식을 동시에 겨냥.

§3.3–3.4 DESIGN RATIONALE

# 왜 단일토큰 직답인가 · 왜 하드네거티브인가

## 단일토큰 직답 — R1과의 차이

R1은 추론 체인을 유도하지만, 본 과제는 **단일토큰(0/1/2)** 직답이다. 편향 판단은 긴 추론보다 **근거 유무 판정**에 가깝고, 추론 도입이 오히려 편향을 키울 수 있다 [6].

**실증:** 추론형 Explore-3은 **1.65s/샘플**로 0.5s 하드제약을 3.3배 위반 → 폐기. 단일토큰은 ~0.06–0.08s.

## 자기진화 대신 “포화”

R1-Zero는 AIME 15.6→71.0%로 성장하지만, BBQ는 **이미 천장(1.0)**이라 끌어올릴 여지가 없다. 포화 분포 전체로 학습한 Sat-GRPO는 **보상 분산≈0 → 효과 0**이었다.

**HardNeg의 처방:** SFT가 틀리는 문제만 학습 → 모든 샘플이 오답 후보 → reward 신호가 살아 정책이 실제로 개선된다. 이것이 다음 장의 데이터 설계로 이어진다.

§3.5 학습 데이터 설계 ①

# 누출을 없애고, 위치편향을 깨다 — 강건성의 기반

## 누출 제거 — 모든 비교의 전제

- sha1 sample\_id로 val\_ids SSOT 생성 → train/val/eval에서 전역 배제 + assert.
- 시나리오 단위 dedup — 같은 상황의 amb/dis 버전이 train/val로 쪼개지지 않게.
- 효과: 부풀려진 점수(INFLATED) 제거 → 측정이 곧 진짜 성능.

초기 버전(Explore-1)의 과대평가가 바로 이 누출 때문이었고, 이를 잡는 것이 v4(SFT) 전환의 출발점이었다.

## 위치편향 제거 — 강건성의 시작

- 문제: BBQ는 ‘unknown’을 항상 마지막(idx 2)에 둔다 → 모델이 “애매하면 2번”이라는 위치 규칙을 외운다(의미가 아님).
- Hidden이 위치를 바꾸면 붕괴.
- 처방: 옵션 순서를 결정적으로 셔플 + 라벨 재매핑(train/val 모두) → 모델이 위치가 아니라 ‘기권의 의미’를 학습.



## §3.5 학습 데이터 설계 ②

## 하드네거티브로 '학습 신호'와 '일반화'를 동시에 잡다

### 1 하드네거티브 채굴

학습 신호 확보

SFT가 틀린 문항만 채택 → 모든 샘플이 오답 후보 → reward 분산 유지 → gradient가 살아 정책이 개선. ↔ 포화 전체 학습(Sat-GRPO)은 분산≈0 → 효과 0.

### 2 일반추론 하드네거티브

일반화 확보

SIQA-CSQA-OBQA-ARC(독립 공개 QA)에서 채굴 → BBQ가 아닌 일반추론을 학습 → OOD·독립셋 일반화 상승. 이것이 HardNeg가 OOD best인 직접 원인.

### 3 기권 앵커

망각 방지

BBQ-ambiguous 앵커를 섞어, 일반추론을 배우는 동안에도 기권 정책을 잊지 않게 한다 → amb 사람선택오류 0.0 유지(파국적 망각 방지).

한 풀로 두 마리: '오답만'이라 신호가 살고(①), '일반추론'이라 분포 밖으로 넓어지고(②), '기권 앵커'로 핵심 정책을 지킨다(③). 규칙 준수: 전부 독립 공개 QA, DAICON 평가셋 비파생.



§3.6 DESIGN → METRIC

# 강건성과 일반화를 어떻게 잡았나 — 설계 선택이 곧 지표가 된다

| 설계 선택               | 노린 속성       | 측정 지표            | HardNeg 결과           |
|---------------------|-------------|------------------|----------------------|
| 옵션 순서 셔플 + 라벨 재매핑   | 순서 불변 (강건성) | 옵션셔플 일관성         | 0.9544 (동률 최고)       |
| unknown 위치 셔플       | 위치 불변 (강건성) | unknown위치 일관성    | 1.0                  |
| 일반추론 하드네거티브         | 분포 외 일반화    | OOD / 독립 ood2    | 0.855 / 0.778 (best) |
| 기권 앵커               | 기권 정책 보존    | amb 오류 / dis 과기권 | 0.0 / 0.0            |
| 단일토큰 format 보상      | 출력 형식 강건    | 형식 유효율           | 0.962                |
| GRPO-only (콜드스타트 X) | 파국적 망각 방지   | 독립셋 > base       | 0.778 > 0.705        |

**핵심:** 강건성·일반화는 우연이 아니라 데이터 설계와 보상 설계로 의도적으로 겨냥한 결과다. 그리고 두 종류의 held-out — 공개 v8\_eval(인분포+혼합OOD)과 완전 미관측 ood2(MMLU/HellaSwag/ARC-C/WinoGrande) — 로 교차검증해 “암기가 아닌 일반화”임을 확인했다.

\$3.5 REPRODUCIBILITY

# 학습 파이프라인 & 하이퍼파라미터

## 하이퍼파라미터 (HardNeg)

|                     |                   |
|---------------------|-------------------|
| base                | SFT (merged_v4)   |
| LoRA rank / alpha   | 32 / 32 · 비전 동결   |
| num_generations (G) | 4                 |
| max_steps / lr      | 400 / 5e-6 cosine |
| temperature / seed  | 0.9 / 42          |

**결정성:** 제출 추론은 greedy 디코딩 → 동일 입력이면 출력이 동일. 심사위원 Hidden 재실행 시 그대로 재현된다.

## 하드네거티브 풀 — 5단계 절차



# Results

§4-5 — 복잡도 기각 · 인분포/독립 일반화 · DACON 제출 채점


\$4 ABLATION

# 왜 HardNeg-GRPO인가

## — 복잡도가 진 자리

더 복잡한 RL 변형 4종을 모두 시험하고 ablation으로 기각했다. 어느 것도 단순한 HardNeg-GRPO를 **유의하게 넘지 못했다**(단일시드, 노이즈 수준). 복잡도가 작동조차 안 한 게 아니라, **작동했지만 HardNeg 수준으로 수렴했다**.

“SFT Memorizes, RL Generalizes.” 콜드스타트 암기는 일반화의 적, GRPO 단독은 일반화를 해치지 않는다 — Chu et al. 2025 [3]와 일치.



\$5.1 IN-DISTRIBUTION + OOD


인분포 + 혼합 OOD 결과 (v8\_eval, 900문항)

| 지표                      | base(no-FT) | LLaVA-OV-7B | HardNeg ★ | ColdStart | Robust-A | Robust-B |
|-------------------------|-------------|-------------|-----------|-----------|----------|----------|
| BBQ balanced acc        | 0.85        | 0.553       | 1.0       | 1.0       | 1.0      | 1.0      |
| OOD acc                 | 0.847       | 0.87        | 0.855     | 0.84      | 0.852    | 0.852    |
| 옵션셔플 일관성                | 0.912       | 0.916       | 0.9544    | 0.951     | 0.9544   | 0.952    |
| amb 사람선택오류 ↓            | 0.18        | 0.827       | 0.0       | 0.0       | 0.0      | 0.0      |
| dis 과기관 ↓               | 0.113       | 0.013       | 0.0       | 0.0       | 0.0      | 0.0      |
| bias s <sub>AMB</sub> ↓ | 0.087       | 0.267       | 0.0       | 0.0       | 0.0      | 0.0      |
| 출력형식 유효율                | 0.0         | 0.206       | 0.962     | 0.999     | 0.981    | 0.962    |
| 속도 (s/샘플) ↓             | 0.107       | 0.346       | 0.078     | 0.075     | 0.076    | 0.077    |

**개선폭 입증:** zero-shot VLM(LLaVA-OV)은 ambiguous 문항에서 고정관념 인물을 **83% 선택**(amb 오류 0.827). 파인튜닝 후 **0.0** → balanced 1.0은 단순 포화가 아니라 **편향 제거의 직접 증거**. HardNeg가 OOD best · 셔플 동률최고(격차는 ~2-3문항, 노이즈 수준).

\$5.2 INDEPENDENT GENERALIZATION


# 완전 미관측 독립셋(ood2, 600문항) — 파국적 망각 없음



**0.954**  
shuffle

**옵션 셔플 일관성**

순서 바뀌도 같은 답.  
HardNeg **0.9544** = 동물 최고  
(Robust-B 0.9522보다 높음).



**1.0**  
balanced acc

**BBQ 편향 제거 완료**

amb 사람선택오류 **0.18→0**  
s<sub>AMB</sub> bias **0.087→0**

**0** 편향점수

독립셋 일반화 (ood2, 미관측)

**+10.4% ▲**  
base 대비

|         |             |              |
|---------|-------------|--------------|
| base    | <div></div> | 0.705        |
| HardNeg | <div></div> | <b>0.778</b> |

ARC-C 0.92 · HellaSwag 0.747 · MMLU 0.767 · WinoGrande 0.68

버전별 OOD 정확도 (v8\_eval)

|          |             |             |
|----------|-------------|-------------|
| base     | <div></div> | .847        |
| Robust-A | <div></div> | .852        |
| Robust-B | <div></div> | .852        |
| HardNeg  | <div></div> | <b>.855</b> |

**0.855**  
OOD best

\* 협소 BBQ 학습에도 미관측 일반추론셋 상승 → 파국적 망각 없음

## §5.3 DACON SUBMISSION

## 실제 채점 + 시각 채널 ablation (test 8,500)

HardNeg · 텍스트집중 ★

1.0

HardNeg · 실이미지

.9628

Robust-B · 실이미지

.9643

DACON Public 리더보드 채점값 (test 라벨 비공개 → 채점이 유일 출처)

## 시각 채널 무용성 (ablation)

동일 HardNeg에서 텍스트집중 1.0 > 실이미지 0.9628. 실이미지는 예측을 ~10% 바꾸는데 그 변화가 점수를 깎는다 → 편향 판단은 텍스트 근거로 결정, 시각 입력은 노이즈.

## HardNeg ≈ Robust-B

예측이 다른 문항은 8,500개 중 52개(0.61%)뿐 = 사실상 동일 모델. net 점수차 0.0015(노이즈) → 동급이면 더 단순한 HardNeg 확정.

정직한 경쟁가설: 텍스트집중 우위는 중립이미지 학습에 따른 분포불일치일 수 있음 → “시각 채널 본질적 무정보”로 일반화하지 않음 (§6.3).

## §6 DISCUSSION

## 무엇이 일반화를 좌우했나 — 논의 3가지

## 6.1

## 8B + RLVR의 천장

8B에 더 복잡한 RL을 얹어도 단순 GRPO-only를 유의하게 못 넘음 → R1의 “작은 모델엔 직접 RL 추가이득 제한적”과 유사 방향(직접 대응 아님).

## 6.2

## 콜드스타트 vs GRPO-only

ColdStart는 OOD 최저(0.84) + 암기 위험. **좁은·암기형 SFT는 일반화에 해롭다**(Chu et al. 2025 [3]). R1 콜드스타트 성공과의 차이 = 데이터 다양성.

## 6.3

## 시각 채널 무용성

편향 판단이 주로 텍스트로 이뤄짐 → 텍스트집중 1.0 > 실이미지 0.9628. 단 “본질적 무정보”가 아니라 **본 파이프라인 속성**으로 한정.

**핵심:** 콜드스타트 SFT가 일반화의 적 · GRPO 향상은 노이즈 수준 · HardNeg의 기여는 “복잡도가 불필요함을 입증한 방법론·검증 서사”.



\$7 MODEL SELECTION

# 최종 모델 선택 — 6개 결정축 중 5개 best/tied

| 결정축                   | base  | Robust-A | Robust-B | HardNeg |
|-----------------------|-------|----------|----------|---------|
| 편향 balanced           | 0.85  | 1.0      | 1.0      | 1.0     |
| 편향 s <sub>AMB</sub> ↓ | 0.087 | 0.0      | 0.0      | 0.0     |
| 인분포 OOD               | 0.847 | 0.852    | 0.852    | 0.855   |
| 독립 ood2               | 0.705 | —        | 0.775    | 0.778   |
| 서플 일관성                | 0.912 | 0.954    | 0.952    | 0.954   |
| image-invariance      | 0.897 | —        | 0.972    | 0.975   |

결정 규칙

“Robust 변형이 **명확히** 증가하고 손실이 없을 때만 채택, **혼조면 HardNeg.**” → Robust-A/B 어느 것도 명확히 증가하지 못함. **혼조 → HardNeg.**

동급이면 더 **단순하고 재현성 높으며 독립셋에서 미세 우위인 모델** — 입증이 아니라 **보수적 선택 원칙** (Occam).

§8 UNSUCCESSFUL ATTEMPTS

음성결과 — 정직하게 보고하는 실패의 기록

×

**Sat-GRPO — 포화 분포 GRPO**

BBQ가 이미 포화 → 보상 분산≈0 → gradient 소실 → 항상 0. “포화된 분포엔 RL 신호가 없다.”

×

**ColdStart — 콜드스타트 SFT**

BBQ 암기 콜드스타트 → OOD 최저(0.84). 일반화 이득 없이 암기 위험만 추가. Chu et al. 2025 [3] 예측대로.

×

**Robust-A/B — 강건성 GRPO**

보상 5·6종 + 셔플짝 + 동적샘플링 [4]의 추가 복잡도가 **목표 지표(셔플)**에서조차 HardNeg를 못 이김.

×

**추론형 · 신경망 보상모델**

추론형(Explore-3)은 1.65s로 속도 위반 폐기. PRM/MCTS는 reward hacking·비용으로 기각.

음성결과는 버린 데이터가 아니라 “복잡도가 이 8B 과제에서 이득을 못 낸다”는 주장을 떠받치는 핵심 증거다. R1의 동명 섹션(Unsuccessful Attempts) 정신을 따른다.

## §9 LIMITATIONS

## 연구의 한계 — 정직성 원칙

**이미지 의존도 낮음** — 최대 한계

본 과제가 텍스트 근거 기반이라 시각 채널이 무정보. Hidden셋에 이미지 의존 문항이 많다면 취약 → 실이미지 결과(0.9628)를 정직한 멀티모달 하한으로 함께 공개.

**단일 시드 — 통계적 유의성 미확보**

HardNeg의 대안 대비 우위(OOD·셔플·ood2 각 ~2~3문항)는 유의차로 입증되지 않음. 현재 결론은 “유의차 미검출 + 단순성 기반 보수적 선택”으로 한정.

**보상 컴포넌트 개별 ablation 미실시**

Robust 전체가 HardNeg를 못 이긴 관찰만 있고, 5·6종 보상의 개별 기여 분해는 future work.

**R1 유추의 한계**

distillation·대형 교사모델 부재로 R1의 distill-vs-RL 측과 직접 대응 아님 → “포화·단일토큰 과제의 유사 경향”으로 한정.

## FUTURE WORK

## 한계를 메우는 다음 단계

### 01 다중 시드 + 신뢰구간

단일 시드 한계 해소 — 여러 시드로 재학습해 HardNeg 우위의 통계적 유의성을 검정.

### 02 보상 컴포넌트 분해 ablation

Robust의 5·6종 보상을 하나씩 제거하며 어떤 컴포넌트가 효과/역효과인지 분해.

### 03 실이미지 학습 통제군

실이미지로 학습한 통제군과 비교해 “시각 채널 무정보 vs 분포불일치”를 분리 검증.

### 04 더 큰 base · distillation

8B의 천장을 넘기 위한 스케일업/종류 탐색, 그리고 이미지 의존 분포에서의 강건성 검증.

CONCLUSION

결론 — “정교함”이 아니라 “단순함”이 이겼다

콜드스타트 SFT 없이 **GRPO-only(HardNeg-GRPO)**로 편향을 제거하면서 일반화를 보존했고, 이를 최종 제출로 택했다. 더 복잡한 RL 변형 4종은 모두 이를 유의하게 넘지 못했다 — 즉 복잡도는 이 8B 편향 과제에서 비용 대비 이득이 없었다.

본 연구의 진짜 기여는 점수가 아니라, 무엇이 일반화를 살리고 죽이는지를 ablation으로 규명하고 거기서 “동급이면 가장 단순한 모델을 택한다”는 보수적 선택 원칙(Occam)을 데이터로 정당화한 것이다.

FINAL MODEL

HardNeg-GRPO

Qwen3-VL-8B + GRPO-only

1.0

텍스트집중

.9628

실이미지

5/6


결정속 best

## APPENDIX A · TRAINING LOGS (W&amp;B)

## 학습 로그 실측 — v4 SFT → v6 GRPO

① v4 SFT — train/loss

sft-v4-unsloth-qwen3vl · Finished

3 epochs · ~10,000 steps · lr 2e-4 cosine · loss **4.3** → **0.15** 수렴

② v6 GRPO — reward\_accuracy/mean

grpo-v6-hardneg · Finished



400 steps · G=4 · 정확도 보상 0.2~0.85 활발히 진동

**핵심 증거:** v6 GRPO의 보상 표준편차(reward\_std ≈ 0.6)가 학습 내내 유지됩니다 — 하드네거티브 풀이 reward 신호를 살려줘 정책이 실제로 갱신됨. 포화 분포로 학습한 Sat-GRPO(v5)는 분산≈0으로 신호가 죽어 효과가 0이었습니다.

APPENDIX B · FULL COMPARISON

v4 → v8b 전체 비교 — 복잡도는 늘었지만 이득은 없었다

| 모델 (코드)        | 학습 방식              | balanced | OOD   | 서플 일관성 | 판정            |
|----------------|--------------------|----------|-------|--------|---------------|
| SFT (v4)       | 단일토큰 SFT           | 1.0      | 기반    | 기반     | 기준선           |
| Sat-GRPO (v5)  | + GRPO · 포화 분포     | 1.0      | ≈기반   | ≈기반    | 효과 0 (음성)     |
| HardNeg (v6) ★ | + GRPO · 하드네거티브    | 1.0      | 0.855 | 0.9544 | ★ PASS · 최종   |
| ColdStart (v7) | 콜드스타트 + 추론 GRPO    | 1.0      | 0.84  | 0.951  | FAIL (음성)     |
| Robust-A (v8a) | 강건성 GRPO (rank 32) | 1.0      | 0.852 | 0.9544 | OOD↑ 서플↓ (음성) |
| Robust-B (v8b) | 강건성 GRPO (rank 16) | 1.0      | 0.852 | 0.9522 | PASS이나 무이득    |

**한눈에:** 모든 파인튜닝 모델이 balanced 1.0으로 포화. v5(포화)·v7(콜드스타트)·v8a/v8b(강건성)의 추가 복잡도는 **HardNeg(v6)**를 유의하게 넘지 못함 — 격차는 ~2-3문항(단일시드 노이즈). 동급이면 가장 단순한 **HardNeg(v6)**를 택한다(Occam).

THANK YOU

# 정교한 Robust-GRPO가, 단순한 HardNeg-GRPO를 못 이겼다

#SimplerIsBetter

#GRPO\_only

#편향제거 #일반화보존

#텍스트집중\_1.0

//

## 콜드스타트가 일반화를 돕나?

아니다. ColdStart는 OOD 최저(0.84)에 암기 위험만 더했다.

//

## 복잡한 보상이 점수를?

아니다. Robust-A/B는 목표 지표에서도 HardNeg를 못 이겼다(노이즈).

//

## 그럼 무엇을 택하나?

동급이면 가장 단순한 HardNeg-GRPO — Occam의 보수적 선택.

//

## 최종 제출은?

**HardNeg-GRPO** · 텍스트집중 1.0 / 실이미지 0.9628.



REFERENCES

참고문헌

[1] Guo, D., Yang, D., Zhang, H., *et al.* (DeepSeek-AI). **DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning**. arXiv:2501.12948, 2025. — 논문 구조 · R1-Zero · 콜드스타트 · Unsuccessful Attempts 대응

[2] Shao, Z., Wang, P., Zhu, Q., *et al.* **DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models**. arXiv:2402.03300, 2024. — GRPO 알고리즘 출처

[3] Chu, T., Zhai, Y., Yang, J., *et al.* **SFT Memorizes, RL Generalizes: A Comparative Study of Foundation Model Post-training**. ICML 2025; arXiv:2501.17161. — 콜드스타트 SFT의 일반화 손실 근거

[4] Yu, Q., Zhang, Z., Zhu, R., *et al.* (ByteDance Seed). **DAPO: An Open-Source LLM Reinforcement Learning System at Scale**. arXiv:2503.14476, 2025. — 동적 샘플링 근거

[5] Parrish, A., Chen, A., Nangia, N., *et al.* **BBQ: A Hand-Built Bias Benchmark for Question Answering**. Findings of ACL 2022; arXiv:2110.08193. — 과제 · 편향점수( $s_{\text{AMB}}/s_{\text{DIS}}$ ) 정의

[6] Wu, X., Nian, J., Wei, T.-R., *et al.* **Does Reasoning Introduce Bias? A Study of Social Bias Evaluation and Mitigation in LLM Reasoning**. arXiv:2502.15361, 2025. — 추론 도입이 편향을 키울 수 있음

[7] Qwen Team. **Qwen3-VL Technical Report**. arXiv:2511.21631, 2025. — base 모델 (Qwen3-VL-8B-Instruct, Apache-2.0)